

用于 ENSO 预测的深度学习

ELNiño/Southern 振荡 (ENSO) 的变化与各种区域气候极端和生态系统影响有关。因此, 长期预测对管理政策响应是有价值的。但是尽管有数十年的努力, 在超过一年的时间上, 预测 ENSO 事件仍然存在问题。在这里, 我们提出了一种采用深度学习方法的统计预测模型, 能够进行成熟的 ENSO 预测, 并且预测时间长达一年半。为了规避有限的观察数据, 我们首先使用迁移学习在历史模拟数据中训练卷积神经网络 (CNN), 随后于 1871 年至 1973 年进行再分析。在 1984 年至 2017 年的验证时段, CNN 模型预测的 Nino3.4 指数的全季 correlation skill 远高于当前最先进的动态预测系统。CNN 模型也更好地预测海面温度的详细区域分布, 克服了动态预测模型的弱点。热图分析表明 CNN 模型使用物理上合理的前体预测 ENSO 事件。因此, CNN 模型是一种强大的工具, 可用于预测 ENSO 事件和分析其相关的复杂机制。

预测大规模气候变化的能力对全球社会和环境系统会造成影响, 其高度依赖于 ENSO 预测的质量。虽然 ENSO 使用大气-海洋耦合模型, 其通常优于当前统计模型, 是最先进的动态预测系统, 但尽管如此, 其仍然不能提供超过一年的有效预测。因此, ENSO 事件的多年预测仍然是一个重大挑战。然而在 ENSO 中存在振荡成分, 与慢慢改变的海洋变化和与其耦合的大气相关, 这表明多年的预测是可行的。有趣的是, 在几个 La Niña 活动期间, 赤道太平洋异常延迟了几年。虽然高频赤道风不太可预测, 但是与底层海表面温度 (SST) 相关的赤道风的缓慢变化成分可预测。赤道太平洋外部的 SST 异常可能导致时间滞后超过一年的 ENSO 事件。这些研究暗示了仍然有改善 ENSO 预测的余地, 尽管目前的方法可能不适合这一点。

随着大数据时代的出现, 深度学习通过发现大型数据集内的复杂结构, 对许多域产生巨大影响。特别地是, CNNs 在使用空间结构处理多维矩阵数据方面产生了出色的结果。因此, CNN 是合适地去揭示三维预测因子和预报量之间的关系。在这里, 我们使用基于 CNN 的统计模型来预测 ENSO 指标。

我们的 CNN 模型使用 SST 和位于 0° - 360° E, 55° S- 60° N 区域的连续三个月的热量 (在海表面垂直 300 米的平均温度) 异常图作为预测因子, 以 Nino3.4 指数 (面积平均超过 170° - 120° W, 5° S- 5° N) 作为预测量, 预测到未来两年 (图 1, 方法)。

对气候预测应用深度学习的最大限制之一是观察期太短而无法实现适当的训练。从 1871 年全球海洋温度分布才可观察。这意味着, 对于每个日历月, 样本数量小于 150。为了大幅提升训练数据的数量, 我们利用了参与 CMIP5 的气候模拟方法的输出, 该方法中 ENSO 是在某种程度上进行模拟的 (扩展数据表 1)。从 1871 年到 1973 年的重分析数据也被用于训练 CNN 模型。验证 correlation skill 的数据则是从 1984 年至 2017 年 (扩展数据表 2)。我们在训练数据的最新一年和验证数据的最早的一年之间留下了十年的差距, 以避免训练数据中海洋的记忆对验证产生可能的影响。

我们应用迁移学习的技术来使用 CMIP5 的输出和重分析数据来最优地训练 CNN 模型。该技术使用从类似的有更多数量样本的任务中获取到的知识, 来执行目标任务。在该研究中, 首先使用 CMIP5 输出训练 CNN 模型, 然后将训练后的权重用作初始权重, 以使用重分析数据训练出最终 CNN 模型。使用 CMIP5 数据的 CNN 中的系统误差, 在使用重分析数据机械能第二次训练期后被校正。

图 2a 显示了从 1984 年到 2017 年,每三个月滑动平均的 Nino3.4 指数的全季 correlation skill。在超过六个月的情况下,在 CNN 模型中的 Nino3.4 指数的预测效果系统地优于所有最先进的动态预测系统。并且 CNN 模型是前六个月的预测时间内具有最佳预测效果的两种模型之一。CNN 模型中 Nino3.4 指数的全季 correlation skill 高于 0.5 的时间长达 17 个月,而领先的动态预测系统 SINTEX-F,在第 17 个月的预测时间时 correlation skill 为 0.37。我们得出结论,CNN 模型为前 1.5 年的 ENSO 事件提供了成熟的预测:这是使用最先进的预测系统无法实现的结果。除了与之前的统计方法相比的深度学习算法的优越性之外(扩展数据图 1 和扩展数据表 3),CNN 模型的效果改进是由于大量 CMIP5 样本和成功的应用了一定程度的迁移学习技术(扩展数据图 2)。

CNN 模型的效果受训练数据集(补充图 1)的变化影响不大。CNN 模型甚至(在 1.5 的预测时间内具有超过 0.5 的 correlation skill)在预测一些能够捕获现实 ENSO 变化的 CMIP5 的模型建模过 ENSO 指数上是成功的(补充图 2-4)。改变训练和验证数据集产生的效果不确定性很小,表明 CNN 可以提供熟练的实时预测。

与 SINTEX-F 相比,CNN 模型还显示了在几乎所有目标季节的 NINO3.4 指标上的更高的 correlation skill。correlation skill 的改进对于针对晚期春季和秋季之间的季节的预测尤其稳健。例如,目标是 5 月至 7 月(MJJ)季节的预测,在 SINTEX-F 中仅有 4 个月超过 0.5 的 correlation skill,而与之相比 CNN 中最多有 11 个月。这降低了不同目标季节之间 CNN 的预测效果的差距,我们得出结论,CNN 模型受春季可预测性障碍的影响较小。

对 18 个月中 12 月至 2 月(DJF)季节的 Nino3.4 指数预测表明,CNN 模型能够正确预测 ENSO 幅度(图 3a)。要了解 CNN 模型如何成功预测 Nino3.4 指数,我们为 1997/98 ELNiño 事件的 18 个月的预测产生热图(图 3b)。热图衡量了预测因子在每个网格点对的预测值的贡献;热图中的正(负)值表示某些区域上的预测因子有助于预测正向(负向)Nino3.4(方法)。在 1997/98 年的 DJF 季节的预测因子热图(1996 年 MJJ 季节的异常)表明,热带西太平洋的异常,印度洋和亚热带大西洋(图 3b 中的红色阴影)是 1997/98 ELNiño 的成功预测的主要贡献者。

热图体现的海洋信号可以在物理的基础上解释 1997/98 ELNiño。南部热带西太平洋的活跃的热含量异常为连续 ELNiño 发展积累热量。在西南印度洋上的惰性的 SST 异常有助于在 1996 年的晚秋的负印度洋偶极子(IOD)(扩展数据图 3a 和 4b)。负 IOD 在随后的季节(扩展数据图 3b 和 4d)期间导致惰性 SST 异常,影响了整个印度洋,在赤道西部太平洋上触发了西风,因此在一年后诱发了 ELNiño 事件。此外,在 MJJ 1996 年北方亚热带大西洋的惰性 SST 异常通过激发中纬度太平洋变化(扩展数据图 3c, d 和 4a)导致了 1997/98 ELNiño 事件。

除了 ENSO 幅度之外,ELNiño 事件的全球影响根据 ELNiño SST 异常的详细区域分布而变化大大变化:central-Pacific 型(CP 型)和 eastern-Pacific 型(EP-Type) ELNiños。因此,基于 SST 异常的区域 ELNiño 类型的成功预测对于提高全球气候预测的质量至关重要。为此,我们设置了一个额外的 CNN 模型来预测 ELNiño 的类型。在该模型中,预测值对应于三个 ELNiño 类别的百分比:CP 型,EP 型和两者的混合作用型。三种类型中具有最高概率的类别被认为是最终预测类别。我们强调,重分析数据不用于训练预测 ELNiño 类型的 CNN 模型,因为已知在重分析训练数据中的 ELNiño 事件是单一类型。因此,我们仅使用

CMIP5 模型输出的数据来训练 CNN 模型预测 ELNiño 的类型，并且我们不应用迁移学习技术。

我们做了一系列用于提前预测 ELNiño 事件类型的环球实验，在验证集上（1984-2017）CNN 模型的命中率为 66.7%。在 95% 置信区间下随机预测中的命中率为 12.5% 和 62.5%，因此 P 值为 0.016 的 66.7% 的 CNN 命中率明显更好。相比之下，动态预测模型的统计预测效果没有一个比随机预测更好的，这意味着 CNN 模型克服了最先进的预测模型的长期弱点。这表明基于深度学习的模型可以精确地预测 ELNiño 事件的空间复杂性。

除了预测 ENSO 强度和类型外，CNN 模型还允许我们识别是哪个 SST 信号导致 EP 型或 CP 型的 ELNiño 事件。为此，我们计算五个海洋盆地（扩展数据图 5）的区域平均热图值。然后，我们选择两个海洋盆地具有最大热图值的两个案例，这可以被认为是研究 EP 型或 CP 型 ELNiño 事件的最有利模式。

尽管从混合型 ELNiño 发生的几年中选择了一些模式，但现有的文献和附加分析表明，所选模式可导致 EP 型或 CP 型 ELNiños。对于 EP 型的 ELNiño，在目标季节前一年的选定的热含量异常可以诱导 ELNiño 成熟阶段前的一个季节的活跃 IOD（图 4e）。对于 CP 型 ELNiño，北热带大西洋的 SST 冷却是被表现了出来（图 4f, g）。我们的结果与先前的研究的结果一致。南太平洋和印度洋的 CP 型 ELNiño 前体尚未报告，另外的分析表明，所识别的前体可以引导 CP 型 ELNiño 事件（扩展数据 6）。这表明 CNN 可以是揭示复杂的 ENSO 机制的强大工具。然而，未来的研究应该是探索样本大小有限的 CNN 模型所展示的统计关系的物理机制。

相较先前的模型，CNN 优势来自使用卷积操作成功提取输入变量的特征。CNN 能够识别那些可被编码成各种不同形状的基本形状，从而表现出与平移和变形的部分不变性。因此，在 CNN 内，即使详细的空间分布已被典型的移位或变形，但是在 CNN 内，输入信号仍然可以正确影响预测值。此外，卷积过程允许 CNN 模型使用相对少量的气候样本进行适当训练。

深度学习导致了許多预测地球系统组成方面的进步，但到目前为止，其在气候预测中的应用仍然罕见。通过使用迁移学习和热图分析来实现深度学习的成功应用，从而预测和理解一个气候现象，这样的工作可以增强工程与地球科学之间的跨学科研究。